SOP-UQ：工具数据有噪声时，估计 agent 答案的出错概率并决定是否核验

版本：服务协议 2.2，主数据格式 2.1（2026-10-12）。考试流程、费用、工具和评分的具体规则见《详细规则》（`docs/rules.md`）。

1. 背景

凌晨两点，一家工程服务公司用 AI 助手处理三类工单（图 1）：给一批待运化学品确定危险品等级；核对一架刚换完部件的飞机的检查和维修记录，判断能否放行（只看记录，不做实际的适航检查）；给一位投诉网速慢的用户诊断、修复网络，并判断问题是否已经解决。



图 1　三类工单对应的现场。左：美国运输部的危险品标签；中：机务人员检查发动机；右：电信运营商的网络运维中心。图片均为公有领域，来源见 `docs/figures/CREDITS.md`。

三类工单都有标准作业流程（SOP）。助手按流程调用评分服务、检查系统和网络诊断工具，再给出结论。多数时候结论是对的，但工具返回的数据不一定可靠：某个分数可能是几天前存下的旧记录；两个看起来一致的读数可能来自同一个数据源；修复后的网络指标可能正好落在” 已解决” 和” 需升级” 的分界附近。出现这些情况时，助手的回答格式照样规范，它自报的把握也照样很高。

值班工程师没法逐单复查，也不能全部放行。需要判断的是：哪些答案可以直接用，哪些值得花钱再查一个关键事实（例如请实验室复测、派检查员到现场），哪些应该直接交给专家。本题研究的就是这个判断。

这个问题在工程上很常见：

- **错误的代价不对称。**低估危险品等级可能导致运输事故，把不该放行的飞机放行比推迟一个航班严重得多；交给专家只是多花一些时间和人力。
- **读数可能出错，多个读数也不一定独立。** 2018 年和 2019 年的两起波音 737 MAX 事故中，机动特性增强系统（MCAS）只依据一个攻角传感器的输入工作，而这个传感器的读数是错误的（印尼国家运输安全委员会 KNKT 2019 年最终报告）。飞机上通常装有多个攻角传感器（图 2），但只有在系统真正比较相互独立的读数时，冗余才能发现错误。



图 2　C-17 运输机机身上的攻角传感器。多个传感器只有在读数相互独立、并且被实际比较时，才能发现错误。图片为公有领域，来源见 `docs/figures/CREDITS.md`。

- **核验要花钱，模型通常改不了。**企业用的往往是供应商提供的固定模型，能改进的是模型外面的一层：估计风险，决定查什么、什么时候转人工。
- **现场条件会变。**现场读数的可靠性常常和开发时不同，而带标签的数据大多来自熟悉的条件。

讨论 agent 时通常假设工具可靠，不确定性只来自模型。本题中，一个答案是否出错同时取决于：工具链（有的工具准确、有的有噪声，前一步的读数决定后面的调用）；模型本身（可能用错规则、漏看字段，自报的把握不一定准）；两者的相互作用（读数接近边界或互相矛盾时模型更容易错，模型调用什么工具又决定它能看到什么）；以及观测条件的变化（读数的可靠性随数据源、业务阶段和条件而变）。

全部任务都在模拟环境中进行，数据为合成数据，判定以本题公开的业务规则为准，结果不能当作真实的危险品分类、适航或维修结论。上面的场景和事故只用来说明工程背景。

2. 任务

初始答案。对测试案例 i，记主评分字段的真实值为 y_i。考官用固定的 agent 运行每个测试案例，得到初始答案 a_i 和它的可见历史 H_i（工具回执、模型输出和共享采样）。所有考生拿到同一组 (a_i, H_i)。初始答案是否出错记为

$$e_i = \mathbf{1}\{a_i \neq y_i\}.$$

飞机任务的七个主字段必须全部正确才算正确，另外两个任务各只有一个主字段。没有合法答案时 $e_i = 1$。

第一步：查询前风险。对每个测试案例提交

$$p_i \approx P(e_i = 1 \mid I_i),$$

其中 I_i 是提交时能合法看到的全部信息：固定历史 H_i、本题已调用的普通工具结果，以及从其他题目获得的信息。

第二步：查询与决策。 360 道测试题中有 72 道交互题。交互题可以调用普通工具；先锁定本题的 p_i 之后，还可以调用 oracle 查询某个字段的真实值。之后可以用所附 agent 继续作答，也可以用其他模型或算法，得到最终答案 b_i。此时能合法看到的信息记为 G_i，最终答案是否出错记为 $f_i = \mathbf{1}\{b_i \neq y_i\}$。对每道交互题提交

$$q_i \approx P(e_i = 1 \mid G_i), \qquad r_i \approx P(f_i = 1 \mid G_i),$$

以及决策 AUTO（采用 b_i）或 DEFER（转人工）。q_i 估计的仍是初始答案是否出错，目标是 e_i 而不是 f_i。选择 DEFER 时，有合法的最终答案和概率就一并提交；无法给出时，如实标记失败或缺失，按《详细规则》第 6 节计分。结果表中 p_i、q_i、r_i 分别对应 `p_initial_error`、`p_initial_error_after_queries` 和 `p_final_error`。

你需要实现给出 p_i、q_i、r_i 的风险估计方法，以及决定查什么、何时停止、是否转人工的策略。

主要规则（完整规则见《详细规则》第 1 至 4 节）：

- 初始答案由考官固定，不能修改；可以利用其他题目的信息，也可以在考试中更新方法。
- 本题首次成功核验之后，它的 p_i 不能再改。
- 最多提交 5 个版本；考试期间只返回" 已接收"，所有考生交卷后统一公布成绩。
- 每次工具调用、oracle 查询和转人工都有费用，计入决策损失。
- `dev` 的 120 道题可以不限次数地调用 oracle 做练习，成绩不计入排名。

3. 数据

公开数据包含 660 个有标签的训练案例和 360 个无标签的测试案例，三个业务域各占三分之一。

文件	数量	用途
`data/train/train.jsonl`	360	训练风险模型
`data/train/cal_fit.jsonl`	120	概率校准
`data/train/cal_select.jsonl`	60	选择策略和阈值
`data/train/dev.jsonl`	120	验证、练习和误差分析
`data/test/cases.jsonl`	360	正式测试

每个案例包含版本号、数据批次、案例编号、业务域和输入字段；训练案例另有 `label`（主评分字段的真实值）和所属划分。各业务域的主评分字段如下。

业务域	主评分字段
危险品	`hazard_class`
飞机部件检查	`aircraft_ready`、`mechanical_inspection_result`、`electrical_inspection_result`、`component_incident_response`、`component_mismatch_response`、`cross_check_response`、`cross_check_reporting_response`
客服排障	`final_resolution_status`

案例的输入字段是准确的，部分工具返回的读数有噪声。每个案例有一个观测条件：标准条件下的读数规律与 `train`、`cal_fit`、`cal_select` 相同；偏移条件下，读数的可靠性会发生变化，具体变化方式不公开。数据中不标注单个案例的条件，各集合的构成如下。

集合	标准条件	偏移条件
`train`、`cal_fit`、`cal_select`	540	0
`dev`	60	60
测试	180	180
其中的交互题	36	36

哪些字段有噪声、工具的几种读取方式、回执字段的含义，见《详细规则》第 5 节。各业务域的 SOP 和判定规则见 `public_specs/`。

4. 模型与 baseline

正式考试默认使用 `Qwen/Qwen3.5-9B`（M9），关闭 thinking，greedy 解码。对给出合法初始答案的案例，在同一份历史上再采样四次，供所有风险估计方法共用。可以自己部署 Qwen，也可以连接考官提供的公共服务。

所附 baseline 的风险估计包括模型自报概率、采样不一致率、训练集错误率、基于公开特征的监督模型和概率校准；策略包括不查询、全部转人工、按阈值转人工、按固定字段查询、查询所有可查字段，以及根据已有数据挑选字段查询的启发式方法。模型配置、参考 agent 和 baseline 的细节见《详细规则》第 7 节。

5. 评测

每个模型分别计算两个主指标，越低越好。两项都先在每个业务域内求平均，再对三个业务域等权平均；分母是全部案例，漏交的题不会被排除。

最终评估通过答辩进行，客观性能指标作为参考。考生应在报告和答辩中说明方法、实验依据和适用范围。

查询前风险的 Brier score。记 S_d 为业务域 d 的测试案例集合，

$$B = \frac{1}{3}\sum_{d}\frac{1}{|S_d|}\sum_{i\in S_d} s_i, \qquad s_i = \begin{cases}(p_i - e_i)^2, & p_i \text{ 有效},\\ 1, & \text{否则}.\end{cases}$$

(q_i, e_i) 和 (r_i, f_i) 用同样的公式在交互题上计算并报告。

交互题的平均决策损失。记 c_i 为第 i 题已发生的全部工具和 oracle 费用，T_d 为业务域 d 的交互题集合，

$$L_i = c_i + \begin{cases}0.5, & \text{转人工},\\ 0, & \text{自动处理且} f_i = 0,\\ 1, & \text{自动处理且为普通错误},\\ 5, & \text{自动处理且为严重错误，或答案无效},\end{cases} \qquad D = \frac{1}{3}\sum_{d}\frac{1}{|T_d|}\sum_{i\in T_d} L_i.$$

严重错误指：低估危险品等级（包括把应为 `Unable to Decide` 的案例判为某个等级）；把不该放行的飞机判为 `aircraft_ready=true`；把没解决的客服问题判为 `RESOLVED`。

允许将需要作出 AUTO/DEFER 决策的题全部转人工，作为一个简单的对照策略；查询前的风险仍按要求提交。

有效性、记 5 的完整情况、辅助指标（NLL、ECE、AP、AURC 等）和置信区间见《详细规则》第 6 节。

6. Technical report

报告围绕下面三个问题展开，附主要结果、必要的消融实验和复现方法。

建议主要在训练集和验证集比较不同方法、完成消融实验，使用相同的初始答案和历史，分别记录各方法的调用和费用。正式测试中，各方法共用已经查到的信息和累计费用，因此这些结果不代表各方法分别从头运行的表现。交卷时的报告可以使用训练和验证结果；正式测试指标由考官统一计算，供答辩参考。

1. **能否准确识别模型可能答错的案例？**固定基础 agent，比较自报概率、采样不一致率和你的风险估计方法。说明训练、校准和选择数据各自的用途；报告概率误差、校准和排序效果，用训练和练习案例分析” 高置信但答错” 和” 低置信但答对” 的原因，并讨论观测条件变化时估计是否仍然可靠。
2. **新获得的数据如何改变对出错的判断？**研究查哪个字段、什么时候查、什么时候停止。区分” 对初始答案风险的更新” 和” 最终答案的变化”，并与不查询、按固定字段查询、查询全部可查字段三种

做法比较。在相同预算下做消融，分析同一数据源的重复读数、采样时间和查询顺序对结论的影响；调用次数多不等于信息多。

3. **如何在错误、查询和转人工之间做取舍？**把风险估计接入完整策略，与按阈值转人工、全部转人工比较，报告决策损失、自动处理比例和费用。在练习数据上分析费用变化、预算限制和失败案例，说明改进来自更准确的风险估计、有效的查询，还是更多的转人工，并给出适用条件、局限和复现所需的配置。

公开报告不能包含测试题的 oracle 返回值、服务凭据或其他考生的材料（见《详细规则》第 8 节）。