# SOP-UQ 快速上手

服务协议 3.0 · 主数据格式 2.1 · 考生版

本文说明如何连接考官服务，并用测试 notebook `scripts/test_example.ipynb` 走完整个流程。题面（完整规则）见 `docs/problem_statement.pdf`。

## 1. 安装

在 `sop_uq_candidate/` 目录的 bash 或 zsh 中（需要 conda；Windows 请用 WSL）：

```
source conda_env.sh      # 首次创建 conda 环境 sii_uq（几分钟），以后只激活
export SOP_EXAMINER_URL=http://<考官地址>:8801 SOP_EXAMINER_TOKEN=<本队 token>
export SOP_MODEL_URL=http://<模型地址>:18080 SOP_MODEL_TOKEN=<模型 token>
jupyter notebook scripts/test_example.ipynb
```

`conda_env.sh` 按 `environment.yml` 安装 Python 3.12、本包与 Jupyter，环境损坏时自动修复；每个新终端先运行它。不用 conda 的安装方法见 `README.md`。

## 2. 数据

下表列出 `data/` 下的全部文件，路径均相对于考生包目录。

| 文件 | 内容 |
|---|---|
| `data/train/train.jsonl` | 训练题输入与标签，用于学习风险估计方法 |
| `data/train/cal_fit.jsonl` | 校准题输入与标签，用于校准预测概率 |
| `data/train/cal_select.jsonl` | 输入与标签，用于选择查询策略和转人工阈值 |
| `data/train/dev.jsonl` | 验证题输入与标签，用于调参和误差分析 |
| `data/test/cases.jsonl` | 测试题输入，不含标签 |
| `data/test/initial_M9.jsonl` | Qwen 的固定初始答案、工具调用记录和共享采样结果 |
| `data/manifest.json` | 数据版本、各 JSONL 文件的行数和 SHA-256 校验值 |

`.jsonl` 文件采用 JSON Lines 格式，每行一个 JSON 对象。测试输入与初始轨迹按 `case_id` 对应，不按行号配对。交互题名单由 `examiner.spec()["interactive_ids"]` 给出，题目文件不单独标注。业务规则和工具说明见 `src/baselines/resources/`，字段的完整说明见 `README.md`。

## 3. 工具与 oracle

`examiner.episode(case_id)` 打开一题，`examiner.tool(episode_id, name, arguments, mode)` 调用业务工具，`examiner.oracle(episode_id, field, phase)` 读取真值。每题可用的工具及参数见 `episode["view"]["tools"]`：各域 `toolspecs.json` 中的工具，外加 SOP 要求的业务动作（见各域 `amendment.txt`）。

| 业务 | 工具（有噪声的读数） | oracle 字段（phase） |
|---|---|---|
| 危险品 | 四个评分工具 `calculate_sds_label_score`、`calculate_handling_score`、`calculate_transportation_score`、`calculate_disposal_score`，四项评分都有噪声 | `sds`、`handling`、`transportation`、`disposal`（`assessment`） |
| 飞机部件检查 | `VerifyAircraftClearance`、`VerifyMechanicalComponents`、`VerifyElectricalSystems`、`CrossCheckSpecifications` 的结果有噪声；三个 `Report...` 工具据此给出报告结论；`updateMaintenanceRecord` 记录维修记录 | 前四个工具的结果字段（`assessment`） |
| 客服排障 | 按 SOP 顺序：验证账户、认证、建会话与工单、查账户状态（停用时先走付款分支 `transferAccountsPayable`、`checkPaymentStatus`、`checkAccountSuspensionStatus`）、查区域故障、`performTechnicalDiagnostics` 诊断、`executeTroubleshooting` 排障，最后 `updateTicket` 或 `createEscalation`；诊断和排障的 `latency`、`jitter`、`bandwidth` 有噪声 | 这三项：`pre_repair`（诊断后）或 `post_repair`（排障后） |

`mode`：`default` 读主数据源，可能是缓存的旧记录；`refresh`、`remeasure` 重新读主数据源，同一来源的重复读数可能相关；`independent` 读第二个独立数据源。普通调用 0.01，有噪声工具的 `independent` 读数 0.03，oracle 每个字段 0.10，同一字段再读免费；顺序不对时返回 `phase_denied`。有标签题可以不限次数地重新打开，每次都是新的练习。测试题中只有 72 道交互题可以继续调用；每道测试题第一次成功的 oracle 回复带有考官记录的时间 `first_oracle_at`（这一次 `first_oracle` 为真），此后该题的 `p_initial_error` 不得再改，由考官人工核查。

## 4. 测试 notebook 的八节

按所附 baseline 从上到下运行各单元格。前四节各需几秒；第 5 节在有标签题上运行 Qwen，平均每题约 10 秒（客服题约 15 秒；多队共用模型服务时更久）；第 6 节只在 72 道交互题上调用模型，约 1 分钟。

| | 内容 | 你会看到 |
|---|---|---|
| 1 | 连接 | 费用、单题限制、360 道测试题中的 72 道交互题、剩余提交次数 |
| 2 | 数据 | 各划分题数、一道题的输入与标签、冻结初始答案 |
| 3 | 手动调用工具与 oracle | 回执、噪声读数（两个数据源）、oracle 真值、累计费用 |
| 4 | 一次 baseline 作答 | agent 的答案、自报风险、四次采样的分歧率 |
| 5 | 采集轨迹并拟合 | 一次采集 `LIMIT` 题/划分：初始答案、四次采样、一次 oracle 与继续作答；拟合初始与查询后风险 |
| 6 | 测试运行 | 360 题的 `results.csv`；只有交互题调用模型 |
| 7 | 提交 | 本次三项风险与决策代价、剩余次数、目前最好的一次 |
| 8 | 你自己的方法 | 改写风险后检查文件，准备下一次提交 |

第 5 节的 `LIMIT = 4` 只是快速试跑；正式方法应设 `LIMIT = None` 采集全部 660 道有标签题（独占一张 GPU 约 2 小时，多队共用模型服务时更久，请尽早开始）。

另一个 notebook `scripts/baseline_example.ipynb` 在同样的轨迹上离线比较六种风险方法和转人工阈值；它的 `RUN` 默认指向第 5 节的 `.runs/notebook/collect`，用命令行采集时改为 `.runs/collect`。

## 5. 命令行：同样的流程

```
# 一次采集有标签题：初始轨迹 + 每题一次 oracle 后的继续作答
# （--limit 为每个划分的题数；不写则全部）
sop-candidate collect --limit 4 --policy fixed --output .runs/collect
# 拟合初始风险与查询后的两项风险
sop-candidate fit --trajectories .runs/collect --output .runs/cal.json
# 测试运行、检查并提交（每次有效提交用掉一次机会）
sop-candidate run --calibrator .runs/cal.json --uq calibrated_disagreement \
    --policy fixed --output .runs/test
python scripts/run_test.py .runs/test/results.csv
python scripts/run_test.py --submissions
# 有标签题的结果可在本地评分，不占次数
python scripts/run_test.py .runs/collect/results.csv --local
```

每个输出目录可中断续跑；改了方法设置时请换一个新的 `--output`。

## 6. 结果文件 results.csv

每道测试题一行，列为

```
case_id, initial_answer_json, p_initial_error, mode,
final_answer_json, p_initial_error_after_queries, p_final_error
```

- 答案为 JSON 对象，无答案留空；三项概率为 [0,1] 内的数值，无法产生时留空。
- 非交互题只填前三列；交互题的 `mode` 为 `AUTO` 或 `DEFER`。
- `initial_answer_json` 必须等于冻结的初始答案。
- 用 `test_client.write_results` 写文件，用 `test_client.results.check_results` 在提交前检查。

## 7. 提交与成绩

每次有效提交立即返回完整评分：三项风险（Brier、NLL、ECE、AP、AURC，按业务域和三域平均）与交互题的决策代价。格式错误会被拒绝；与已评分文件完全相同的文件直接返回原报告；两者都不占次数。每队最多 5 次，成绩取主指标（默认是 $p_i$ 的三域平均 Brier，越低越好）最好的一次。测试题的工具和 oracle 费用记在本队台账中，重跑不会清零。

评分反馈用于评估自己的方法；考官信任各队，不得用它推断测试标签（例如逐题改变风险值比较分数）。比较不同方法请在有标签题上进行：测试题台账由各方法共用。

## 8. 常见错误

| 错误码 | 含义与处理 |
|---|---|
| `unauthorized` | 考官或模型的 token 不对或没设置（`SOP_EXAMINER_TOKEN`、`SOP_MODEL_TOKEN`） |
| `noninteractive_case` | 这道测试题不允许再调用工具或 oracle |
| `phase_denied` | 业务步骤顺序不对，例如客服未诊断就查指标 |
| `budget_exhausted`, `tool_limit`, `oracle_limit` | 本题已用完预算 2.00、24 次工具调用或 16 次 oracle |
| `invalid_results` | 文件未通过检查（格式、取值，或初始答案不等于冻结答案），消息写明行或 `case_id`；不占次数 |
| `no_tries_left` | 本队的提交次数已用完 |
| `model_busy` | 共享模型繁忙；客户端会自动等待重试 |