SOP-UQ 快速上手

服务协议 3.0 · 主数据格式 2.1 · 考生版

本文说明如何连接考官服务，并用测试 notebook `scripts/test_example.ipynb` 走完整个流程。题面（完整规则）见 `docs/problem_statement.pdf`。

考官（每队一个实例）	考生
业务工具、噪声读数、oracle 真值	运行 agent，估计三项风险
本队台账：每道测试题的累计费用	决定查询哪些事实、`AUTO` 或 `DEFER`
评分：每次提交立即返回，最多 5 次	写出 `results.csv` 并提交

1 开始

1.1 安装与连接

在 `sop_uq_candidate/` 目录的 bash 或 zsh 中（需要 conda；Windows 请用 WSL）：

```
source conda_env.sh      # 首次创建 conda 环境 sii_uq（几分钟），以后只激活
export SOP_EXAMINER_URL=http://<考官地址>:8801 SOP_EXAMINER_TOKEN=<本队 token>
export SOP_MODEL_URL=http://<模型地址>:18080 SOP_MODEL_TOKEN=<模型 token>
jupyter notebook scripts/test_example.ipynb
```

`conda_env.sh` 按 `environment.yml` 安装 Python 3.12、本包与 Jupyter，环境损坏时自动修复；每个新终端先运行它。不用 conda 的安装方法见 `data/README.md`。

1.2 测试 notebook 的八节

从上到下逐格运行即可。前四节几秒到几分钟；第 5 节在有标签题上运行 Qwen，平均每题约 1 分钟（客服题较长，个别需数分钟；共享 GPU 时更久）；第 6 节只有 72 道交互题调用模型，约几分钟。

	内容	你会看到
1	连接	费用、单题限制、360 道测试题中的 72 道交互题、剩余提交次数
2	数据	各划分题数、一道题的输入与标签、冻结初始答案
3	手动调用工具与 oracle	回执、噪声读数（两个数据源）、oracle 真值、累计费用
4	一次 baseline 作答	agent 的答案、自报风险、四次采样的分歧率
5	采集轨迹并拟合	一次采集 `LIMIT` 题/划分：初始答案、四次采样、一次 oracle 与继续作答；拟合初始与查询后风险
6	测试运行	360 题的 `results.csv`；只有交互题调用模型
7	提交	本次三项风险与决策代价、剩余次数、目前最好的一次
8	你自己的方法	改写风险后检查文件，准备下一次提交

第 5 节的 `LIMIT = 4` 只是快速试跑；正式方法应设 `LIMIT = None` 采集全部 660 道有标签题（独占一张 GPU 约 10 小时，多队共用模型服务时更久，请尽早开始）。

另一个 notebook `scripts/baseline_example.ipynb` 在同样的轨迹上离线比较六种风险方法和转人工阈值；它的 `RUN` 默认指向第 5 节的 `.runs/notebook/collect`，用命令行采集时改为 `.runs/collect`。

1.3 命令行：同样的流程

```
# 一次采集有标签题：初始轨迹 + 每题一次 oracle 后的继续作答
# （--limit 为每个划分的题数；不写则全部）
sop-candidate collect --limit 4 --policy fixed --output .runs/collect
# 拟合初始风险与查询后的两项风险
sop-candidate fit --trajectories .runs/collect --output .runs/cal.json
# 测试运行、检查并提交（每次有效提交用掉一次机会）
sop-candidate run --calibrator .runs/cal.json --uq calibrated_disagreement \
    --policy fixed --output .runs/test
python scripts/run_test.py .runs/test/results.csv
python scripts/run_test.py --submissions
# 有标签题的结果可在本地评分，不占次数
python scripts/run_test.py .runs/collect/results.csv --local
```

每个输出目录可中断续跑；改了方法设置时请换一个新的 `--output`。考官另开边界检查集时，用它的地址和 token，并给 `run` 和 `run_test.py` 加上 `--data data/challenge`（另用一个 `--output`）。

1.4 结果文件 results.csv

每道测试题一行，列为

```
case_id, initial_answer_json, p_initial_error, mode,
final_answer_json, p_initial_error_after_queries, p_final_error
```

- 答案为 JSON 对象，无答案留空；三项概率为 [0,1] 内的数值，无法产生时留空。
- 非交互题只填前三列；交互题的 `mode` 为 `AUTO` 或 `DEFER`。
- `initial_answer_json` 必须等于冻结的初始答案。
- 用 `test_client.write_results` 写文件，用 `test_client.results.check_results` 在提交前检查。

1.5 提交与成绩

每次有效提交立即返回完整评分：三项风险（Brier、NLL、ECE、AP、AURC，按业务域和三域平均）与交互题的决策代价。格式错误会被拒绝；与已评分文件完全相同的文件直接返回原报告；两者都不占次数。每队最多 5 次，成绩取主指标（默认是 p_i 的三域平均 Brier，越低越好）最好的一次。测试题的工具和 oracle 费用记在本队台账中，重跑不会清零。

评分反馈用于评估自己的方法；考官信任各队，不得用它推断测试标签（例如逐题改变风险值比较分数）。比较不同方法请在有标签题上进行：测试题台账由各方法共用。

1.6 常见错误

错误码	含义与处理
`unauthorized`	考官或模型的 token 不对或没设置（`SOP_EXAMINER_TOKEN`、`SOP_MODEL_TOKEN`）
`noninteractive_case`	这道测试题不允许再调用工具或 oracle
`phase_denied`	业务步骤顺序不对，例如客服未诊断就查指标
`budget_exhausted`, `tool_limit`, `oracle_limit`	本题已用完预算 2.00、24 次工具调用或 16 次 oracle
`invalid_results`	文件未通过检查（格式、取值，或初始答案不等于冻结答案），消息写明行或 `case_id`；不占次数
`no_tries_left`	本队的提交次数已用完
`model_busy`	共享模型繁忙；客户端会自动等待重试