SOP-UQ 详细规则

本文件是题面（`docs/problem_statement.md`）的补充，列出考试流程、提交、费用、数据与工具、评分和 baseline 的具体规则。符号含义与题面相同。

1. 考试流程

1. 正式测试共 360 题。考官事先用固定 agent 生成每题的初始答案 a_i、调用记录和共享采样，所有考生使用同一份。提交的初始答案必须与考官记录一致；考官记录为失败的题，不能标为 `completed`。
2. 其中 72 道是交互题，可以调用普通工具和 oracle；其余 288 道不能调用任何工具，只评估查询前风险 p_i。哪些题是交互题由服务告知。
3. 交互题调用 oracle 之前，必须先用 `checkpoint_initial` 登记本题的 p_i（也可以登记为失败或缺失状态）。在首次成功核验之前仍可修改 p_i，修改后须重新登记；首次成功核验之后，p_i 不能再改。是否成功以考官服务的记录为准；网络响应丢失时，用原来的 `request_id` 重试取回结果。如果正式考试有多个初始模型，同一题所有模型的 p_i 一起锁定。
4. 尚未成功核验过的题，p_i 可以在后续提交版本中修改，以最后一个版本为准。
5. 预测时可以利用其他题目的信息，可以在考试中更新方法参数，也可以更换后续求解的模型或算法。方法和配置的变化要记录下来，便于复现。
6. 调用记录、费用和额度按" 考生 + 试卷" 统计。更换方法、模型、运行或提交版本都不会重置。

2. 提交与交卷

1. 每名考生最多提交 5 个不同版本。每个版本包含全部题目；每道交互题的终局记录必须在该题最后一次调用之后提交。
2. 重复上传已经接收的版本，不计次数，即使后来又进行了调用。取得新的调用结果后重新确认答案，即使答案内容相同，也可以形成新版本。格式错误或与服务端记录不一致的包会被拒绝，也不计次数。
3. 第 5 个版本被接收后自动交卷；也可以在提交至少一个版本后提前交卷；到截止时间自动交卷，此前没有提交过版本的记为未提交。
4. 计分时，已经成功核验过的题使用锁定的 p_i；其余题的 p_i，以及所有交互题的 b_i、q_i、r_i 和决策，使用最后一个版本。费用按交卷时的累计值计算，包括最后一个版本之后发生的调用。
5. 考试期间每次提交只返回" 已接收"，不返回分数、错误率或任何与标签有关的信息。所有考生交卷或考试截止后，考官统一公布成绩，并永久关闭本场考试的报名和修改；公布过成绩的测试数据不能再用于下一批考生。
6. 需要提交：可运行的代码、配置、训练得到的模型和校准文件；用所附客户端生成的 `submission.zip`（包含 `manifest.json` 和 `results.csv`）；technical report。初始答案和已锁定的风险必须与服务端记录一致，终局答案和风险必须基于该版本提交时的最新调用记录；费用和调用次数以服务端记录为准。公开报告与给考官的复现材料分开提交。

3. 费用与预算

操作	每次费用
普通工具调用	0.01
用 `independent` 方式读取可能有噪声的字段（第 5 节）	0.03
调用 oracle 查询一个字段	0.10
转人工（DEFER）	0.50

1. 正式测试中，每道题的工具和 oracle 费用合计不超过 2.00，其中普通工具最多 24 次，oracle 最多 16 次；考官生成初始答案时已发生的费用也计入。
2. 网络重试同一请求不重复收费，新的请求照常收费；对已经查过的 oracle 字段再次查询，会免费返回原结果。
3. 2.00 的预算主要用于防止资源滥用，对现有的合理查询路径一般不构成约束，因此不能据此说明方法在预算紧张时的表现。研究预算约束时，可以使用 0.50 或 1.00 的公开配置，在相同配置下重新采集参考轨迹和校准数据，并单独报告。

4. dev 练习

1. dev 的 120 道题用于练习，其中 60 道为偏移条件。
2. 练习时 oracle 不限次数、不计入预算、不需要锁定风险；提交后立即返回成绩，不计入排名，也不占测试的提交次数和额度。名义费用仍会记录，便于比较策略。
3. 练习中每道题的普通工具仍限 24 次，用完可以开始新的练习。
4. 练习入口不能访问测试题。

5. 数据与工具

有噪声的字段。案例的输入字段是准确的。工具返回的结果中，只有下表中的字段可能与真实值不同，其他返回值都准确。oracle 只能查询这些字段，每次返回一个字段在指定业务阶段的真实值；危险品的四个分数在 oracle 中分别叫 `sds`、`handling`、`transportation` 和 `disposal`。客服任务要先调用 `performTechnicalDiagnostics` 才能查询 `pre_repair` 阶段的值，调用 `executeTroubleshooting` 之后才能查询 `post_repair` 阶段的值。

业务域	可能有噪声的字段（返回该字段的工具）
危险品	`sds_label_score`、`handling_score`、`transportation_score`、`disposal_score`（四个 `calculate_*_score` 工具）
飞机部件检查	`aircraft_ready`（`VerifyAircraftClearance`）、`mechanical_inspection_result`（`VerifyMechanicalComponents`）、`electrical_inspection_result`（`VerifyElectricalSystems`）、`cross_check_response`（`CrossCheckSpecifications`）
客服排障	`latency`、`jitter`、`bandwidth`（`performTechnicalDiagnostics` 和 `executeTroubleshooting` 返回的服务指标）

观测条件。每个案例有一个观测条件，它只影响上表字段的读数，不改变业务规则和标签。标准条件下的读数规律与 `train`、`cal_fit`、`cal_select` 相同；偏移条件下，这些读数的可靠性会发生变化，具体变化方式不公开，不同偏移案例之间也不完全相同。`dev` 中有 60 道带标签的偏移条件案例，使用了它们的方法不能声称没有用过偏移条件的标签。数据中不标注单个案例的条件。

数据源与读取方式。返回有噪声字段的工具可以在请求中指定 `mode`。每个业务域有两个数据源：`default`、`refresh` 和 `remeasure` 读取主数据源，`independent` 读取第二数据源。名字只说明读取的是哪个数据源，不保证两者的误差统计独立。回执中的 `source_id` 标识数据源，同一业务域的所有案例共用这两个标识；同一数据源的读数共享该数据源的误差特性，不能当作相互独立的证据。

`mode`	数据源	费用	返回的记录
`default`	主数据源	0.01	可能是之前存下的旧记录；同一字段、同一阶段重复请求总是返回同一条记录
`refresh`	主数据源	0.01	不使用 `default` 存下的记录，但不保证是本次新采的记录。危险品分数和飞机的四个字段在每个数据源、每个阶段只有一条当前记录，重复请求返回同一条；客服指标重复请求可以得到新读数，其中第一次与 `default` 不用旧记录时的读数相同

mode	数据源	费用	返回的记录
remeasure	主数据源	0.01	目前与 refresh 完全相同，两者共用编号：第 n 次 remeasure 与第 n 次 refresh 返回同一条记录
independent	第二数据源	0.03	返回第二数据源在本阶段的当前记录。危险品分数和飞机的四个字段每个阶段只有一条；客服指标从第二次请求起每次返回新读数

其他工具不受 mode 影响，任何方式都按 0.01 收费。

回执字段。 observation_id 是记录编号：两个读数的编号相同，说明是同一条记录，第二次读取没有带来新信息。sampled_at 是记录的采样时间，observed_at 是本次请求的业务时间；sampled_at 早于 observed_at，说明返回的不是本次采样的记录。客服的诊断和排障工具一次返回三个指标，每个指标的 field、source_id、sampled_at 和 observation_id 列在回执的 observations 中。

其他说明。

- SOP、工具说明、输出格式和业务规则随代码提供；每个案例实际可用的工具和参数以服务返回为准。工具请求只能包含工具 schema 中声明的参数；oracle 只接受服务规定的字段和业务阶段。
- 工具调用成功只表示这次调用完成，不表示模型的结论正确。客服的读数要按业务阶段解读，后一阶段的状态只有完成规定操作后才能读取。
- challenge_data/ 另附 72 个边界案例，包括恰好在阈值上、略低或略高于阈值、单项异常等情况；它们使用独立的数据版本，只用来检查规则实现，不计入测试成绩。
- 主数据是合成数据。去重会改变生成参数给出的比例；校准集和交互题按业务分支覆盖挑选，其中的比例不代表真实场景的发生率。危险品任务考察的是根据工具给出的分数分类，不考察阅读真实 SDS 文档的能力；飞机的 aircraft_ready 只表示行政和维修记录上的放行结果，不是真实的适航结论。

6. 评分细节

有效性。 p_i 要求初始状态为 completed，r_i 要求终局状态为 completed，q_i 要求两者都为 completed。状态为 failed 或 missing 时，对应的答案按错误计，风险按缺失计，缺失风险的 Brier 项记为 1；初始状态失败不影响已完成终局的评分。服务拒绝非有限值或超出 $[0, 1]$ 的概率。

违规请求。同一道题中，考生调用工具、oracle 或登记逐题答案时，因违反参数、业务步骤或提交规则而被拒绝的请求累计超过 5 次，就不能继续自动处理这道题。只计算考生本人的请求；上传结果包的格式错误、服务忙、考试已截止或已交卷等情况不计入。此时三项风险都按缺失计，决策损失为已经发生的工具和 oracle 费用加 5，转人工也不能消除这项处罚。

决策损失。每道交互题的损失为已发生的工具和 oracle 费用 c_i，加上：

- 转人工：0.5。终局状态为 completed、failed 或 missing 都按 0.5 计；此时提交的 b_i 和 r_i 仍按上面的有效性规则评估 r_i。
- 自动处理且答案正确：0。
- 自动处理且为普通错误：1。
- 记 5 的情况：自动处理且为严重错误；自动处理但终局状态不是 completed，或答案缺失、不合法；没有提交决策；违规请求超过上述上限。

严重错误指：低估危险品等级，包括把应为 Unable to Decide 的案例判为某个等级；把不该放行的飞机判为 aircraft_ready=true；把没解决的客服问题判为 RESOLVED。转人工后人工的处理结果不作为模型是否出错的标签。

辅助指标。下列指标只使用有效概率，同时报告有效提交的比例（NLL 除外，它在全部案例上计算）。

- NLL：二元交叉熵，有效概率截断到 $[10^{-6}, 1-10^{-6}]$，缺失项记为 $-\log 10^{-6}$。
- ECE 和 aECE：分箱后预测风险与实际错误率之差的加权平均。ECE 用 10 个等宽分箱；aECE 按样本数自适应分箱，概率相同的样本不拆到不同分箱。
- AP：以出错为正类，衡量按风险从高到低排序时能否先找出错误；风险相同的样本作为一组处理，没有正类时不计算。
- AURC：按风险从低到高逐个纳入案例，对各覆盖率下的错误率取平均；风险相同的案例按随机顺序取期望。
- 自动处理比例、自动处理错误率、转人工比例和平均查询费用，用于解释决策损失。

置信区间。主指标附 95% bootstrap 分位数区间：在每个业务域内按案例重抽样 2000 次。这个区间只反映这批案例的抽样波动，不代表分布变化后的表现。报告正式成绩时，要同时给出初始准确率、自动处理比例和业务损失，不能只凭某一项 Brier score 判断模型的业务能力。

7. 模型与 baseline 细节

模型。 M9 为 `Qwen/Qwen3.5-9B`，BF16 权重；M27 为 `Qwen/Qwen3.8-27B` 的 `UD-Q4_K_M` GGUF 量化版本。正式考试默认使用 M9，M27 用于考官另行配置的扩展评测，两者的成绩分开报告，量化方式也属于配置的一部分。文件哈希、tokenizer、推理设置和运行方式见 `model_profiles/`。可以用所附部署代码自己运行 Qwen，也可以连接考官提供的同协议公共服务；Qwen 服务看不到完整数据或真实状态。

参考 agent。参考轨迹关闭 thinking，使用 greedy 解码。对给出合法初始答案的案例，在生成该答案时的同一份历史上再采样四次（temperature 0.7、top-p 0.9、top-k 40），供所有风险估计方法共用；采样中提出的工具调用不会执行。参考 agent 在初始阶段最多调用模型 20 次，继续作答后累计最多 32 次。这是参考 agent 和 baseline 的设置，考生可以用别的方法继续作答。自己部署模型时留下的调用记录用于复现，不能代替考官对模型运行过程的独立核查。

baseline。风险估计包括模型自报概率、采样不一致率、训练集错误率，以及基于公开特征的监督模型和概率校准。策略包括不查询、全部转人工、按阈值转人工、按固定字段查询、查询当前所有可查的字段，以及根据已有数据挑选字段查询的启发式方法。它们只使用公开输入、合法获得的观测、模型输出和训练标签。

- 所附校准文件记录了生成训练轨迹时的模型、提示词、输入整理方式、采样设置、调用上限、风险估计代码、公共协议代码、预算和费用。其中任何一项变化后，旧的校准文件不能直接使用，需要重新采集轨迹或重新拟合。自己实现的在线方法可以随时更新参数，但要记录更新过程。
- 查询后的两个风险，分别用训练数据上的查询轨迹单独校准，并且必须和采集这些轨迹时的查询策略一致。只有在实际要查询时才检查是否有匹配的校准文件；某题没有查询时，直接沿用查询前的风险。不经校准的自报方法在查询前后都使用模型自报的概率，单独比较。
- 转人工阈值在 `cal_select` 或 `dev` 上按实际错误代价选取，手动指定的阈值会标为启发式。普通错误和严重错误的代价不同，只看出错概率不能确定最优决策。
- 程序会报告全部转人工、风险值几乎相同等异常情况。按已有数据挑选字段的 baseline 是启发式方法，不保证查询的信息价值最优。

比较方法时的注意事项。在同一个固定初始 agent 上比较风险估计方法时，使用考官提供的同一批案例和初始轨迹，并报告每种方法新获得的数据和花费。使用其他题目的信息或在线更新的方法，预测时可用的信息与固定历史不同，应记录题目的处理顺序和学习过程；另做一个只用固定历史的对照，有助于解释收益来自哪里。后续求解的模型或算法可以更换，但要区分哪些收益来自更好的求解器，哪些来自更好的风险估计。多个方法或模型共用同一份测试调用记录，按模型分列的费用不能看作各自独立获取信息的成本。

8. 禁止事项与报告要求

1. 不得越权获取测试答案、读取其他考生的记录，或伪造调用、回执和结果来源。自己用模型或算法算出的答案和概率是合法的。
2. 无法给出合法答案或有效概率时，如实提交失败或缺失状态，不得编造。
3. 公开报告只能使用训练标签和公布后的测试汇总结果，不能包含测试题的 oracle 返回值、服务凭据或其他考生的材料；复现材料单独交给考官。