# SOP-UQ 测试说明

服务协议 **3.0** · 主数据格式 **2.1**

## 1. 要解决什么问题

本测试研究：当工具读数有噪声时，如何估计 AI 助手答案出错的概率，并决定是否进一步核验、采用答案或转交人工。三个业务域是危险品分类、飞机部件检查和客服排障。它们是合成教学场景；流程和指标仅用于本测试。

考官先用固定 agent 为每道正式测试题生成初始答案 $a_i$、工具历史和四次共享采样，所有考生获得相同的初始证据。真实答案记为 $y_i$，初始错误为 $e_i = \mathbf{1}\{a_i \neq y_i\}$。非法或缺失答案也算错误。

需要提交三类风险，都是“答案出错的概率”：

| 设置 | 概率 | 判断对象与可用信息 | 适用范围 |
|---|---|---|---|
| 查询前 | $p_i$ | 初始答案 $a_i$，首次核验本题真值之前能合法获得的信息 | 全部 360 题 |
| 查询后回看 | $q_i$ | 仍是初始答案 $a_i$，但可以使用新获得的证据 | 72 道交互题 |
| 最终答案 | $r_i$ | 最终答案 $b_i$，使用查询后的证据 | 72 道交互题 |

查询后的两项分别对应 $P(e_i = 1 \mid G_i)$ 和 $P(b_i \neq y_i \mid G_i)$，其中 $G_i$ 是此时合法可见的信息。修改答案后，$q_i$ 的判断对象仍是原答案。

正式测试共 360 题，每个业务域 120 题。服务指定其中 72 题允许交互，其余 288 题只提交初始风险，不能继续调用工具或 oracle。交互题最后选 `AUTO`（采用 $b_i$）或 `DEFER`（转人工）。转人工时，有合法的答案和概率也应一并提交；无法产生的答案或概率留空。

## 答案字段

答案必须是只含下列主评分字段的 JSON 对象，字段须全部正确才算答对。

- 危险品：`hazard_class`。
- 飞机：`aircraft_ready`、`mechanical_inspection_result`；`electrical_inspection_result`、`component_incident_response`；`component_mismatch_response`、`cross_check_response`；`cross_check_reporting_response`。
- 客服：`final_resolution_status`。

完整业务规则、SOP 和工具 schema 位于 `src/baselines/resources/`。下一页列出容易误读的判定规则；每题实际可调用的工具和参数以考官服务返回为准。

## 2. 业务判定与工具阶段

### 危险品 `dangerous_goods`

读取四个评分工具获得 SDS、操作储存、运输和处置分数。分数为整数 1–5；0 或 `null` 表示缺失。产品未登记、引用无效或缺失分数超过两项时，答案为 `Unable to Decide`。否则，用已知有效分数的最大值填补缺失项，再将四项相加：4–7 为 `Hazard Class A`，8–12 为 B，13–16 为 C，17–20 为 D。输出应使用完整值，例如 `Hazard Class B`。公开文本提供业务背景，不能代替评分工具的观测。

### 飞机检查 `aircraft_inspection`

`aircraft_ready` 是 `VerifyAircraftClearance` 返回的行政与维修记录放行结果，不能用其他检查的合取推导。机械检查成功要求重量在 ±2% 内、序列号一致；这两项只是必要条件。规格核对成功当且仅当重量偏差不超过预期重量的 2%、安装到检查时间在 [0, 24 小时] 内、预期与安装序列号一致，边界均包含在内。

读取全部七项服务结果，包括三项报告服务。报告读取返回已有结果，不会创建报告；报告是否适用与服务返回值不同。按 SOP 调用 `updateMaintenanceRecord`。字段取值：

- `aircraft_ready`：JSON 布尔值 `true` 或 `false`。
- 机械和电气检查：`success`、`fail` 或 `retest`。
- 其余四项：`success`、`failed` 或 JSON `null`。

不添加示例 SOP 中无关的 `VerifyShipment` 字段。

### 客服排障 `customer_service`

账号无效、认证失败或不符合服务条件时为 `FAILED`；10 英里范围内存在故障时为 `PENDING_ACTION`。因欠费停用时，先转 `transferAccountsPayable`，检查已有付款与停用解除记录，不模拟付款。完成适用的账号和故障检查后才能诊断；诊断需要至少一项修复前异常指标。

令 $P$ 为订阅带宽（Mbps），定义

$$D(L, J, B; P) = \max(L/100 - 1, 0) + \max(J/30 - 1, 0) + \max(1 - B/P, 0).$$

排障后，恰在以下条件同时成立时为 `RESOLVED`：$D_{pre} > 0$、$D_{post} \le 0.5 D_{pre}$、$L_{post} \le L_{pre}$、$J_{post} \le J_{pre}$、$B_{post} \ge B_{pre}$；否则为 `ESCALATED`。指标按 0.1 网格取值，等号合格；不存在额外的 “初始指标良好即提前结束” 规则。

`executeTroubleshooting` 的 `root_causes` 必须恰好包含之前诊断返回的全部不同根因；遗漏、多余或重复均被拒绝。一次规范排障将状态从修复前改为修复后，重复调用不再次修复。升级回执只证明已提出请求。按问题性质选择团队，再用 `updateTicket` 记录状态。

## 3. 数据、模型与方法开发

下表路径均相对于 `data/`。

| 文件 | 数量 | 用途 |
|---|---|---|
| `train/train.jsonl` | 360 | 学习风险模型和历史错误率 |
| `train/cal_fit.jsonl` | 120 | 拟合概率校准 |
| `train/cal_select.jsonl` | 60 | 选择策略与转人工阈值 |
| `train/dev.jsonl` | 120 | 练习、调参与误差分析 |
| `test/cases.jsonl` | 360 | 正式测试输入，不含标签 |
| `test/initial_M9.jsonl` | 360 | 考官冻结的初始答案、工具历史与四次采样 |
| `challenge/test/cases.jsonl` | 72 | 独立边界检查，不计入正式成绩 |

题目文件（`train/*.jsonl`、`test/cases.jsonl`）每行是一个 UTF-8 JSON 对象，包含 `schema_version`、`dataset_release_id`、`case_id`、`domain` 和 `inputs`；有标签划分另含 `label` 和 `training_split`。`test/initial_M9.jsonl` 每行是一条冻结轨迹：`case_id`、`domain`、`answer`（初始答案，失败时为 `null`）、`status`、`p_error`（自报风险）、`samples`（四次采样的答案与自报风险）、`history`（模型回复、工具回执与被拒记录）、`messages`（不含系统提示的完整对话，用于继续作答）、`usage`、`cost` 与 `failure`；输入字段见 `test/cases.jsonl`。各划分的三类业务数量相等。`manifest.json` 记录数据批次、行数和 SHA-256；主数据与 challenge 使用各自清单和独立版本。

`train`、`cal_fit`、`cal_select` 共 540 题为标准条件；`dev` 中标准和偏移条件各 60 题；正式测试各 180 题，其中交互题各 36 题。偏移只改变工具读数可靠性，不改变业务规则与标签；单题条件不公开。使用 `dev` 标签的方法须说明使用过偏移条件标签。合成数据的分支覆盖比例不代表真实发生率。

### 开发流程

1. 从考官服务采集公开有标签题的模型与工具轨迹。`train` 表示采集轨迹，不会微调 Qwen。
2. 用 `train` 学习风险估计器，用 `cal_fit` 校准，用 `cal_select` 选阈值；`dev` 用于练习和分析。
3. 需要查询时，使用同一查询策略采集公开查询后轨迹，分别拟合 $q_i$ 和 $r_i$ 的校准器。
4. 测试运行读取考官固定的初始轨迹 `test/initial_M9.jsonl`，估计风险、执行允许的查询，再写出最终结果。

baseline 包含自报风险、采样不一致率、历史错误率、监督模型及校准方法；策略包括不查询、全部转人工、风险阈值、固定字段、全部可查字段和启发式选字段。后者不保证信息价值最优；普通和严重错误的代价不同，仅凭错误概率不能推出最优转人工阈值。

### 模型配置

默认初始模型 M9 为 `Qwen/Qwen3.5-9B` BF16；关闭 thinking，主解码为 greedy。给出合法初始答案后，在同一历史上额外采样四次：temperature 0.7、top-p 0.9、top-k 40；采样提出的工具调用不执行。参考 agent 初始主循环最多生成 20 次，继续作答后累计最多 32 次，另加四次共享采样，单题最多 36 次。上下文上限 16,384 token，单次回复最多 1,024 token；agent 把危险品等级的简写（如 `C`）读作完整取值（`Hazard Class C`）。

`src/qwen_server/profiles/` 还提供 M27 配置（`Qwen/Qwen3.8-27B`、`UD-Q4_K_M` GGUF 与 llama.cpp），可用于查询后的继续求解；正式初始答案只来自 M9。权重另行提供，可连接考官模型服务或自行部署。后续求解可换模型或算法，须记录配置变化。

发布包不含训练好的校准器。模型、提示词、特征、采样、代码、协议、预算或代价变化后，应重新采集或拟合匹配的校准器；查询后的校准还须匹配查询策略。无查询时沿用初始风险。

## 4. 工具、观测与预算

案例输入准确。只有下列工具字段可能有噪声；其他返回值准确。oracle 每次返回一个允许字段在指定阶段的真值。

| 域 | 可能有噪声的字段 | oracle 阶段 |
|---|---|---|
| 危险品 | 四个评分；oracle 字段名为 `sds`、`handling`、`transportation`、`disposal` | `assessment` |
| 飞机 | 放行、机械、电气、规格核对结果 | `assessment` |
| 客服 | `latency`、`jitter`、`bandwidth` | `pre_repair` 或 `post_repair` |

完整字段名见 `spec` 返回的 `oracle_fields`。客服须先完成 `performTechnicalDiagnostics` 才能查修复前值，完成 `executeTroubleshooting` 才能查修复后值。

## 读取模式

`mode` 是工具请求顶层字段，不放进业务 `arguments`。每域两个数据源，跨案例共用 `source_id`；名称为 `independent` 的第二数据源也不保证误差统计独立。

| `mode` | 数据源与返回规律 | 每次代价 |
|---|---|---|
| `default` | 主源，可能为旧记录；同字段同阶段重复读取固定记录 | 0.01 |
| `refresh` | 主源，绕开旧缓存，不保证为本次新采样 | 0.01 |
| `remeasure` | 当前与 `refresh` 完全相同，共用读数编号 | 0.01 |
| `independent` | 第二源的本阶段记录 | 0.03 |

危险品和飞机在每源每阶段各只有一条当前记录；刷新或重复读取不能制造新证据。客服 `refresh` 可获得新读数，第一次与 `default` 不使用旧记录时相同；客服 `independent` 从第二次起每次为新读数。第 n 次 `remeasure` 与第 n 次 `refresh` 返回同条记录。无噪声工具不受模式影响，均为 0.01。

`observation_id` 相同表示同条观测。`sampled_at` 是采样时间，`observed_at` 是本次业务时间；前者更早表示返回旧记录。客服一次返回三个指标，各自的来源、时间和编号在 `observations` 中。同源读数共享误差特性，应结合这些字段识别重复或相关证据。

## 正式测试限制

单题工具与 oracle 总预算 **2.00**，普通工具最多 **24 次**，oracle 最多 **16 次**；考官初始轨迹中的调用也计入。oracle 每字段 **0.10**，重复查询已查字段免费返回原结果。测试题的费用记在本队考官台账中，换方法或重跑都不重置。预算 2.00 主要防止滥用；研究紧预算时可在训练数据上自行模拟 0.50/1.00 预算并单独报告。

工具只接收 schema 声明参数，实体引用必须来自本题；被拒的请求不收费，也不影响后续调用。网络响应丢失时，调用可能已经执行，先用 `history` 查看台账再决定是否重发。

有标签题（`train`、`cal_fit`、`cal_select`、`dev`）每次打开都是新的 episode：限制相同，但互不累计，可以反复练习，并用公开标签在本地评分。测试题每队每题只有一个 episode，各种方法共用其中的证据与费用，结果会受调用顺序影响；比较方法请在有标签题上进行。

## 5. 测试运行与提交

从 `docs/quickstart.pdf` 开始安装和连接。运行入口：

- `scripts/test_example.ipynb`：从连接、手动调用工具与 oracle，到采集、拟合、测试运行和提交的完整流程。
- `scripts/baseline_example.ipynb`：比较六种风险方法与转人工阈值，自行部署 Qwen。
- `sop-candidate`：同样流程的命令行（`collect`、`fit`、`run`、`score`、`submit`）。
- `scripts/run_test.py`：检查并提交 `results.csv`，或在本地为训练/`dev` 结果评分。

### 单题流程

1. 调用 `spec` 查看费用、限制、72 道交互题和剩余提交次数。
2. 读取本题冻结的初始答案、历史与四次共享采样（`data/test/initial_M9.jsonl`）。所有 360 题都估计 $p_i$，不能更换初始答案。$p_i$ 只应使用首次 oracle 之前能获得的信息，由各队自觉遵守。
3. 交互题可继续普通工具调用和 oracle，形成 $b_i$、$q_i$、$r_i$ 与 `AUTO`/`DEFER`。非交互题不能再调用工具或 oracle。

可以使用其他题的合法信息，也可在线更新方法参数；记录题目顺序和更新过程。多种方法共用本队同一台账的证据与费用。

### 文件格式

提交一个 UTF-8 的 `results.csv`，每道测试题一行，列顺序如下：

```
case_id, initial_answer_json, p_initial_error, mode,
final_answer_json, p_initial_error_after_queries, p_final_error
```

答案单元格为 JSON 对象，无答案时留空；三项概率分别填 $p_i$、$q_i$、$r_i$，为 [0,1] 内的数值，无法产生时留空（不能用 0 代替）；`mode` 为 `AUTO`、`DEFER` 或空。

- 非交互题只填前三列。
- 初始答案列必须与冻结的初始答案一致。
- 可选的第八列 `cost` 只用于本地评分；考官使用自己的台账。
- `test_client.results` 中的 `write_results` 写出这一格式，`check_results` 在提交前检查。

### 提交次数与成绩

每队最多 **5 次**有效提交（以 `spec` 为准）；每次立即返回完整评分。格式错误被拒绝，与某次已评分文件完全相同的文件直接返回原报告，两者都不占次数。成绩取主指标最好的一次，默认主指标为 $p_i$ 的域等权 Brier score（越低越好）；所有提交的报告都可随时查看。测试题费用取提交时本队台账的累计值。

评分反馈用于评估自己的方法。考官信任各队：不得利用反馈推断测试标签，例如逐题改变风险值并比较分数。

## 6. 评分、分析与复现

先在每个业务域内平均，再对三个域等权平均；空白行保留在分母中。

### 三项风险

$p_i$ 对初始错误 $e_i$ 计算 Brier score；$q_i$ 仍对 $e_i$，$r_i$ 对最终错误 $f_i$。有效项为 $(p-e)^2$，空白或无效风险记 **1**。缺失或非法答案一律算错误，因此对没有答案的题报告风险 1 得分为 0。

辅助指标包括 NLL、ECE、aECE、AP 和 AURC。NLL 在全部题计算，有效风险截到 $[10^{-6}, 1-10^{-6}]$，缺失记 $-\log 10^{-6}$；其他辅助指标仅用有效项。ECE 为 10 个等宽箱；aECE 同概率不拆箱。AP 以错误为正类、同风险分组，无正例不计算；AURC 对同风险顺序取期望。

### 交互决策代价

单题损失为已发生的工具/oracle 费用 $c_i$，再加下表终局代价：

| 结果 | 终局代价 |
|---|---|
| `DEFER` | 1.0 |
| `AUTO` 且正确 | 0 |
| `AUTO` 且普通错误 | 1.5 |
| `AUTO` 且严重错误、答案无效/缺失，或无决策 | 5.0 |

严重错误：低估危险品等级（包括将应为 `Unable to Decide` 判成某等级）；将不该放行飞机判 `aircraft_ready=true`；将未解决客服问题判 `RESOLVED`。`DEFER` 的答案风险仍照常评分；人工结果不替代模型正确性标签。

### 技术报告与复现材料

报告应说明风险特征、校准数据、查询理由、停止规则和转人工策略。用相同初始证据比较自报风险、采样分歧和自己的方法；再比较不查询、固定查询、全部查询和全部转人工。报告 Brier、校准/排序效果、平均决策代价、自动处理比例及查询代价，分析有把握却答错的案例和偏移条件下的失败。

主要消融在训练与 `dev` 完成，正式测试汇总单独讨论。区别风险估计、查询与求解器变化的收益；记录所有数据使用、模型/软件版本、随机种子、运行命令、处理顺序和在线更新。只用固定历史的对照有助于分析跨题信息收益。

不得越权获取测试标签、他人记录或伪造调用与回执。公开报告可使用训练标签及本队的测试评分汇总，不能泄露测试 oracle 值、服务凭据或他人材料。无法产生合法结果时如实记录失败/缺失。复现代码须能在无考官私有文件的环境运行。